Clasificación de riesgo crediticio mediante Machine Learning sobre datos sintéticos colombianos

Informe técnico final · Machine Learning II
Nicolás Barrera y Angie Loango

1. Problema, propósito y alcance

Se estudia la clasificación multiclase del perfil crediticio (Good, Standard y Poor) mediante Machine Learning. El objetivo es comparar enfoques de distinta complejidad y evaluar si las señales financieras, laborales y de comportamiento permiten recuperar una etiqueta sintética bajo un procedimiento reproducible. La referencia metodológica es Koshti, Molia y Varia (2025), de la que se retoma la comparación de clasificadores; no se replican su población ni sus etiquetas. El ejercicio es experimental y no estima incumplimientos reales.

2. Datos y construcción de la etiqueta

Se generaron 5.000 perfiles artificiales contextualizados con información de la Encuesta Integradora y la encuesta de Pensiones y Parafiscales, según la documentación del equipo. Estas fuentes orientan las características socioeconómicas y laborales; los registros no son respuestas reales de personas. El archivo tiene 25 columnas: 23 predictores, una variable de antigüedad laboral en años que se excluye por redundancia con meses, y la etiqueta Credit_Score. No se identificaron faltantes ni duplicados en la versión analizada.

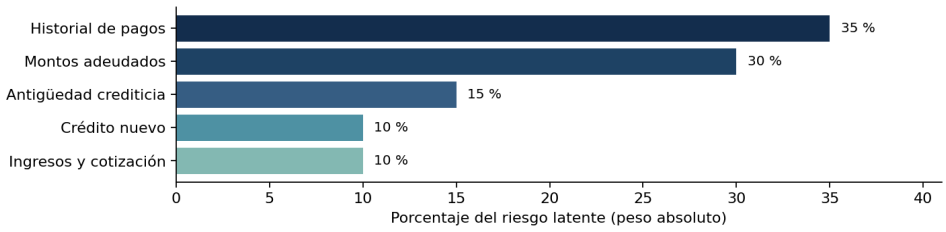
La variable objetivo no es un dato observado: se crea mediante un índice latente de riesgo, perturbación aleatoria y probabilidades softmax para asignar Good, Standard o Poor. Por tanto, el experimento mide recuperación de etiquetas simuladas, no capacidad predictiva de mora real.

3. Fundamentación de las ponderaciones

Para el generador se parte de los grupos publicados por FICO: historial de pagos (35 %), montos adeudados (30 %), antigüedad crediticia (15 %), crédito nuevo (10 %) y mezcla crediticia (10 %). Se conserva la masa de los cuatro primeros grupos; el 10 % de mezcla se reasigna a dos señales laborales colombianas. Las divisiones dentro de cada grupo y el reparto 6 % / 4 % son **supuestos del equipo**, no estimaciones oficiales ni coeficientes empíricos de Colombia.

Factor que genera etiqueta	Peso	Dirección del riesgo
Retrasos / mora / comportamiento de pago	11,67 % cada uno	Mayor deterioro → mayor riesgo
Utilización / deuda-ingreso	15 % cada uno	Mayor proporción → mayor riesgo
Antigüedad crediticia	15 %	Mayor antigüedad → menor riesgo
Consultas de crédito	10 %	Más consultas → mayor riesgo supuesto
Variabilidad de ingreso / meses sin cotizar	6 % / 4 %	Mayor inestabilidad → mayor riesgo supuesto

Los pesos absolutos suman 100 %. La antigüedad se incorpora con signo protector. El índice se construye sobre transformaciones normalizadas de cada factor y se agrega ruido antes de obtener probabilidades por softmax. Para el detalle de cada predictor y sus pesos explícitos —incluidos ceros para evitar doble conteo— véase DOCUMENTACION_23_VARIABLES.md. Los 23 predictores sí participan en el entrenamiento; sus coeficientes son aprendidos por el modelo, no fijados por esta tabla.

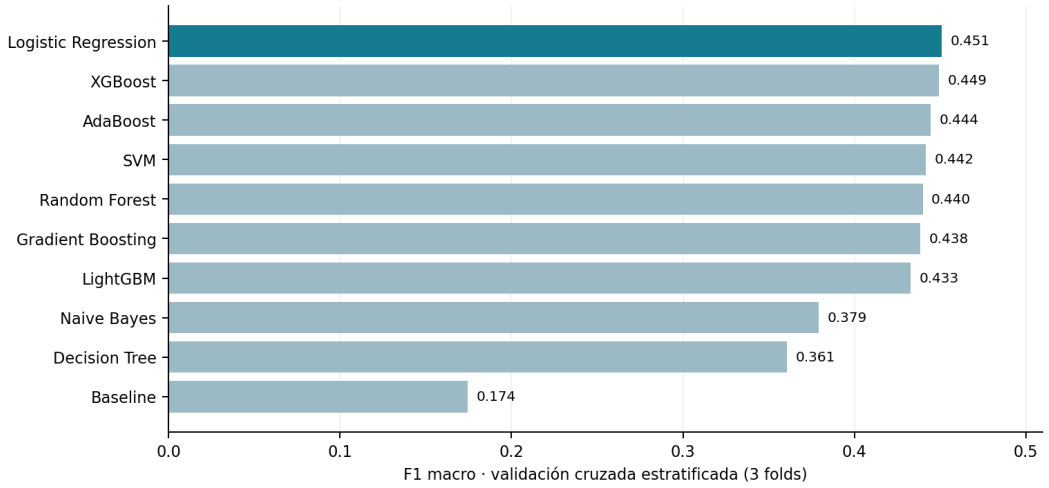


4. Comparación y elección del modelo

Se utilizó partición estratificada 80/20 (4.000 entrenamiento y 1.000 prueba), preprocesamiento en Pipeline, validación cruzada, ajuste de hiperparámetros y validación anidada de finalistas. La métrica de selección es F1 macro para ponderar por igual las tres clases. Se incluyó DummyClassifier como referencia mínima.

Modelo	F1 macro CV	Desviación
Logistic Regression	0.4510	0.0039
XGBoost	0.4495	0.0073
AdaBoost	0.4444	0.0061
SVM	0.4416	0.0105
Random Forest	0.4399	0.0020
Gradient Boosting	0.4384	0.0093
LightGBM	0.4328	0.0077
Naive Bayes	0.3792	0.0568
Decision Tree	0.3608	0.0130
Baseline	0.1745	0.0001

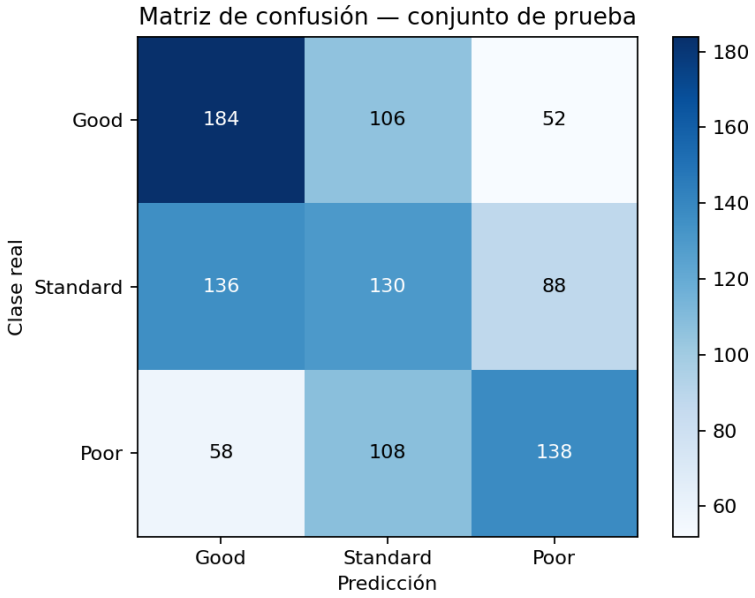
La regresión logística (0,4510) y XGBoost (0,4495) muestran resultados muy cercanos en la comparación inicial; Random Forest obtiene 0,4399 y el Dummy 0,1745. Estas diferencias no demuestran superioridad estadística. Los modelos más flexibles no presentan una ganancia clara frente a una alternativa lineal regularizada sobre este objetivo sintético.



El procedimiento de selección del notebook favorece un modelo más simple cuando su F1 macro anidado queda a menos de 0,01 del mejor finalista. Se seleccionó regresión logística con C = 0,001: regularización intensa, menor complejidad y coeficientes más fáciles de examinar. **La tabla completa de resultados anidados y de modelos ajustados debe exportarse del notebook ejecutado antes de afirmar una ventaja definitiva en esa etapa.** La comparación con el artículo es metodológica: sus cifras sobre otra población no son directamente comparables.

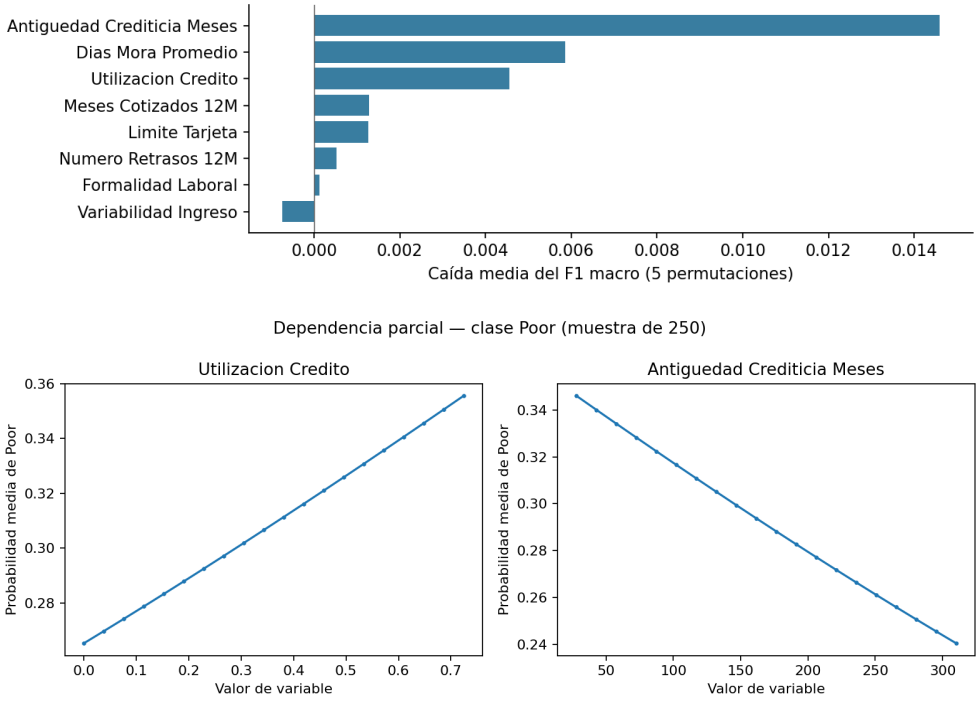
5. Evaluación independiente y errores

En los 1.000 casos de prueba, el modelo seleccionado obtuvo accuracy 0,452; precisión macro 0,454; recall macro 0,453 y F1 macro 0,453 (IC bootstrap 95 %: 0,422–0,486). La clase Standard es la más difícil de recuperar (recall 36,7 %), frente a Good (53,8 %) y Poor (45,4 %). Hubo 58 perfiles Poor predichos Good, un error que sería especialmente preocupante en una aplicación real. Estos resultados no justifican uso crediticio operativo.



6. Interpretabilidad y lectura financiera

La importancia por permutación sobre test sitúa primero la antigüedad crediticia, seguida de días de mora y utilización del crédito; las caídas de F1 son pequeñas y la correlación puede repartir importancia entre predictores. La dependencia parcial estima que, al variar utilización, la probabilidad media de Poor aumenta aproximadamente de 0,265 a 0,356; al variar antigüedad, disminuye de 0,346 a 0,240. Son asociaciones del modelo con datos artificiales, no relaciones causales ni estimaciones poblacionales.



7. Despliegue, limitaciones y proyección

La aplicación Streamlit utiliza el Pipeline y el codificador guardados, recibe los 23 predictores y devuelve la clase junto con probabilidades. Para ejecutarla desde la carpeta del proyecto: `python -m pip install -r requirements.txt` y luego `python -m streamlit run app.py`. Se verificó la carga de artefactos y una predicción; la comprobación visual en navegador requiere evidencia local del equipo.

Las limitaciones principales son: etiquetas simuladas, pesos parcialmente subjetivos, solapamiento entre clases, variables correlacionadas, ausencia de validación externa y falta de calibración frente a incumplimientos observados. Como

continuidad se propone análisis de sensibilidad de pesos, validación temporal con datos autorizados, auditoría de equidad, calibración y seguimiento MLOps; Deep Learning sería una comparación adicional, no una garantía de mejora.

Referencias y declaración

Koshti, R. M., Molia, S. J., y Varia, D. J. (2025). *Improving Credit Score Classification Using Predictive Analysis and Machine Learning Techniques*. https://www.ijsat.org/research-paper.php?id=4759
FICO. *What's in your credit score?* https://www.myfico.com/credit-education/whats-in-your-credit-score
Gutiérrez-Rueda, J., Estrada, D., y Capera-Romero, L. (2011). *Un análisis del endeudamiento de los hogares*. Banco de la República. https://doi.org/10.32468/tef.61

Declaración de IA: Se utilizó inteligencia artificial generativa como herramienta de apoyo en el desarrollo del proyecto.