

SEGUNDA ENTREGA · FASE 2

Clasificación del riesgo crediticio mediante técnicas de Machine Learning

Datos, modelamiento y validación

Integrantes

Nicolás Barrera

Angie Loango

Artículo base

Koshti, R. M., Molia, S. J. y Varia, D. J. (2025). Improving Credit Score Classification Using Predictive Analysis and Machine Learning Techniques. International Journal on Science and Technology, 16(2).

1. Objetivo y datos simulados

La pregunta del proyecto sigue siendo la misma: **¿qué modelo de Machine Learning clasifica mejor el riesgo crediticio de los clientes en Colombia?** Es un problema de clasificación con tres clases: Good, Standard y Poor (la variable `Credit_Score`). No existe una base pública colombiana con todas las variables individuales que necesitamos para repetir el artículo, así que construimos un conjunto simulado de 5.000 registros. La simulación se puede repetir y deja claros sus supuestos; no busca representar a toda la población del país.

Durante la revisión corregimos un problema con la semilla aleatoria: la edad y la ocupación usaban los mismos números al azar, y por eso la ocupación dependía casi por completo de la edad. Ahora la edad usa una semilla distinta (`SEED + 1`). El conjunto final tiene 2.625 dependientes, 1.066 independientes, 876 trabajadores por cuenta propia, 331 desempleados y 102 pensionados, y 126 registros con ingreso mensual igual a cero.

Las fuentes oficiales sirven solo como punto de referencia, no como valores exactos: la GEIH del DANE para la variedad de ingresos y empleos; la UGPP para el 40 % del ingreso neto que se toma como base de cotización de los independientes; y la Superintendencia Financiera junto con Banca de las Oportunidades para el acceso a productos financieros, cartera y mora. Los promedios, dispersiones, probabilidades y topes concretos son supuestos del equipo.

Variable	Distribución / regla	Parámetros	Justificación
Edad	Normal truncada	$\mu=38$; $\sigma=12$; 18-75	Supuesto de población adulta
Ingreso mensual	Lognormal por ocupación y formalidad	medianas base 0,9-4,2 M; tope 30 M	GEIH como referencia de la variedad de ingresos
IBC aproximado	Factor sobre el ingreso	dependiente $\approx 1,00$; independiente $\approx 0,40$	UGPP (40 % para independientes)
Utilización	Beta sobre saldo/límite	Beta(2,2; 3,0)	Concentración en uso bajo-medio
Mora	Gamma según retrasos	parámetros crecientes; tope 120 días	SFC como marco de cartera y mora

Tabla 1. Cómo se generan las variables principales.

`Credit_Score` se calcula a partir de un **puntaje de riesgo** que suma las señales con estos pesos: utilización, deuda/ingreso y retrasos (0,20 cada uno), mora (0,14), comportamiento de pago (0,10), consultas (0,08), variabilidad del ingreso (0,07), discontinuidad de cotización (0,05) y antigüedad crediticia, que protege (-0,08). A ese puntaje se le suma un poco de ruido (desviación 0,12), se convierte en probabilidades (softmax) y la clase se sortea según ellas. Así el resultado tiene señal, pero no es exacto.

Clase	Utilización	Retrasos 12M	Días de mora	Ratio deuda/ingreso
Good	0,203	0,446	2,785	0,148
Standard	0,257	0,642	3,822	0,178
Poor	0,382	1,215	7,688	0,306

Tabla 2. Promedio de las señales de riesgo en cada clase.

La Tabla 2 muestra que la simulación sale como se planeó: utilización, retrasos, mora y deuda suben de Good a Poor. No hay datos faltantes ni duplicados, y las clases están bastante equilibradas (Standard 35,52 %, Good 34,56 %, Poor 29,92 %). Los topes en pesos y el mínimo de 300.000 COP para ingresos positivos son límites de la simulación, no reglas legales.

2. Cómo se repitió y adaptó el método del artículo

El artículo compara nueve algoritmos. Aquí se **probaron los nueve** (Decision Tree, regresión logística, SVM, Random Forest, LightGBM, Gradient Boosting, AdaBoost, XGBoost y Naive Bayes) y se agregó un clasificador de referencia (Dummy) como base mínima. La Tabla 3 muestra qué se mantuvo y qué cambió.

Aspecto	Artículo	Esta adaptación
Datos	≈100.000 registros reales (Kaggle)	5.000 registros simulados con referencias colombianas
Algoritmos	Nueve clasificadores	Los mismos nueve + base de referencia
Variables categóricas	Label encoding	OneHotEncoder (no impone un orden entre categorías)
Preparación de datos	Limpieza y selección antes de modelar	Escalado y codificación dentro de un Pipeline
Selección de variables	Elimina identificadores y variables problemáticas	Se quita Antigüedad_Laboral_Años (repetida); quedan 23 variables elegidas por criterio y sin identificadores
Métrica principal	Accuracy, precision, recall y F1	F1 macro, junto con la matriz de confusión

Tabla 3. Método del artículo frente a esta adaptación.

Los datos se dividieron en 80 % para entrenar (4.000 registros) y 20 % para probar (1.000), manteniendo la proporción de cada clase. El escalado y la codificación se aprenden solo con los datos de entrenamiento de cada partición, para que el conjunto de prueba nunca influya en el entrenamiento.

Por qué usamos F1 macro

Da el mismo peso a las tres clases sin importar cuántos casos tenga cada una, así no se esconde el mal resultado en Standard, la clase intermedia y más difícil. **No mide que unos errores cuestan más que otros**; por eso lo acompañamos con la matriz de confusión y el conteo de errores entre Good y Poor.

Modelo	F1 macro inicial (3 particiones)	F1 tras el ajuste	Configuración ajustada
Regresión logística	0,484 ± 0,008	0,488	C = 0,001
AdaBoost	0,480 ± 0,009	0,486	learning_rate = 0,3; n = 100
SVM	0,471 ± 0,012	0,476	C = 0,5; gamma = scale
XGBoost	0,464 ± 0,006	0,466	lr = 0,03; depth = 2; n = 100
LightGBM	0,458 ± 0,010	—	sin ajuste
Gradient Boosting	0,458 ± 0,007	0,476	lr = 0,05; depth = 2; n = 100
Random Forest	0,451 ± 0,014	0,471	depth = 8; leaf = 1; n = 100
Decision Tree	0,401 ± 0,012	—	sin ajuste
Naive Bayes	0,345 ± 0,057	—	sin ajuste
Baseline (Dummy)	0,175 ± 0,000	—	base de referencia

Tabla 4. Comparación inicial con validación cruzada y resultado del ajuste de hiperparámetros (solo con datos de entrenamiento).

La regresión logística y AdaBoost tuvieron los mejores promedios iniciales. Random Forest quedó más abajo, pero lo ajustamos igual porque fue el mejor en el artículo y porque, sin límite de profundidad, puede sobreajustarse con solo 5.000 registros. También ajustamos SVM, XGBoost y Gradient Boosting; LightGBM, Decision Tree y Naive Bayes quedaron solo como comparación por su menor desempeño. Ampliamos las búsquedas hacia valores más regularizados porque varios mejores resultados quedaban en el borde. Como prueba extra, aplicar log1p a las variables en pesos dentro del SVM dio F1 macro 0,474 ± 0,012, sin mejorar el SVM ajustado, así que no lo usamos.

3. Validación y resultado final

Algunos mejores valores quedaron en el borde de la búsqueda, así que una búsqueda más amplia podría dar cambios pequeños. Aun así, las diferencias entre los modelos competitivos son menores que la variación normal entre particiones, y la regresión logística tiene su mejor valor dentro del rango explorado. Por eso la decisión final se apoya en la validación anidada.

Comparamos los dos mejores modelos con **validación cruzada anidada** (3 particiones externas y 2 internas): en cada partición externa, los hiperparámetros se eligen solo con las internas, lo que reduce el optimismo del ajuste. La regresión logística obtuvo F1 macro 0,471 ± 0,006 y AdaBoost 0,470 ± 0,010; la diferencia es menor que la variación, así que

quedan prácticamente empatados. Elegimos la **regresión logística por ser simple, transparente y fácil de interpretar**, no porque sea claramente mejor.

0,481 Accuracy	0,482 Precision macro	0,483 Recall macro	0,481 F1 macro	0,449–0,512 IC 95 % (bootstrap)
--------------------------	---------------------------------	------------------------------	--------------------------	---

Tabla 5. Resultado final de la regresión logística en el conjunto de prueba (1.000 registros; intervalo con 1.000 repeticiones bootstrap).

Clase	Prec.	Recall	F1	n
Good	0,50	0,58	0,54	346
Standard	0,41	0,36	0,38	355
Poor	0,54	0,50	0,52	299

Tabla 6. Métricas por clase del modelo final.

Standard es la clase más difícil y se confunde bastante con las clases vecinas. Hay **105 errores entre los extremos** (47 Good clasificados como Poor y 58 Poor como Good). Contar estos errores ayuda a ver los fallos más costosos sin convertir F1 macro en una medida de costos.




Figura 1. Matriz de confusión del modelo final.

Aviso sobre el conjunto de prueba

Durante el desarrollo miramos el resultado de una versión intermedia del SVM en el conjunto de prueba. La elección final se hizo solo con validación cruzada y anidada sobre los datos de entrenamiento, pero, en rigor, **el conjunto de prueba ya no está completamente limpio**. En una continuación convendría reservar otro conjunto aparte o generar una nueva muestra simulada.

4. Interpretación, comparación con el artículo y limitaciones

Para ver qué variables pesan más usamos la **importancia por permutación**: se mezclan los valores de una variable en las 1.000 observaciones de prueba (10 veces) y se mide cuánto baja el F1 macro. Se calculó para las 23 variables y se muestran las 15 primeras; las barras indican la desviación estándar. Como varias variables están relacionadas entre sí, la importancia se reparte entre ellas y no debe leerse como causa.

Utilizacion_Credito es la variable más importante (0,018), seguida de Meses_Cotizados_12M (0,010). Variabilidad_Ingreso, Edad, Antigüedad_Laboral_Meses y Tipo_Cotizante aportan menos y con bastante incertidumbre. La edad no entra directamente en el puntaje de riesgo, pero se relaciona con la antigüedad crediticia (correlación 0,766) y la laboral (0,237), por lo que puede estar reflejándolas. Su relación con el número de productos (0,096) y con el límite de tarjeta (0,063) es baja.




Figura 2. Importancia por permutación de la regresión logística (cuánto baja el F1 macro).

Hasta dónde se puede llegar con estos datos

Para saber el máximo posible calculamos qué resultado tendría un clasificador con información perfecta, que conociera las probabilidades reales con las que se generó cada etiqueta: **F1 macro 0,578** (accuracy 0,572) sobre las mismas 1.000 observaciones de prueba. Ni así se acierta siempre, porque la etiqueta final se sortea al azar. Nuestro modelo (0,481) queda por debajo porque tiene que aprender la frontera a partir de 23 variables observadas, sin conocer el cálculo interno del puntaje de riesgo.

Comparación con el artículo. El artículo reporta un F1 cercano a 0,88 con Random Forest en el dataset de Kaggle. No se pueden comparar directamente: cambian el tamaño, la estructura, la selección de variables y la forma de generar los datos. Además, el dataset original tiene registros mensuales por cliente; el artículo dice que elimina ID, Month, Name, SSN, Credit_History_Age y Annual_Income, pero no menciona quitar Customer_Id ni dividir los datos por cliente. No afirmamos que haya fuga de información, pero no queda demostrado que entrenamiento y prueba sean independientes.

Limitaciones.

- Credit_Score se construye sumando señales con pesos, algo que puede favorecer a modelos simples como la regresión logística.
- Los parámetros de la simulación son supuestos del equipo, no estimaciones de la población.
- El conjunto de prueba se consultó en una etapa intermedia.

Aun así, el trabajo es reproducible, compara los nueve algoritmos del artículo, usa validación anidada y reporta la incertidumbre.

Referencias y reproducibilidad

Koshti, R. M., Molia, S. J., & Varia, D. J. (2025). Improving Credit Score Classification Using Predictive Analysis and Machine Learning Techniques. International Journal on Science and Technology, 16(2). <https://www.ijst.org/research-paper.php?id=4759>

DANE. Gran Encuesta Integrada de Hogares (GEIH) – Mercado laboral, empleo y desempleo.

<https://www.dane.gov.co/index.php/estadisticas-por-tema/mercado-laboral/empleo-y-desempleo>. Consulta: 01/10/2026.

UGPP. ABC Trabajador independiente por cuenta propia. https://www.ugpp.gov.co/abc_cuenta_propia/. Consulta: 01/10/2026.

Superintendencia Financiera de Colombia y Banca de las Oportunidades. Reporte de Inclusión Financiera 2025.

<https://www.superfinanciera.gov.co/publicaciones/10116222/>. Consulta: 01/10/2026.

Superintendencia Financiera de Colombia. Estadísticas de evolución de la cartera de créditos.

<https://www.superfinanciera.gov.co/publicaciones/10115251/>. Consulta: 01/10/2026.

Reproducibilidad. El cuaderno se ejecutó completo y las 67 celdas de código tienen contador de ejecución; las versiones de las librerías están en requirements.txt. **Uso de IA.** Usamos IA generativa como apoyo para depurar código, revisar la metodología y redactar; el equipo entiende y puede sustentar las decisiones técnicas.