PLANTEAMIENTO Y DATOS

Clasificación de riesgo crediticio sintético

Informe técnico final · Universidad Externado de Colombia · 2026

Nicolás Barrera · Angie Loango

1. Resumen y planteamiento del problema

La evaluación del riesgo crediticio representa un desafío para las entidades financieras, especialmente cuando se busca identificar patrones en el comportamiento de pago y las condiciones económicas de los usuarios. En este contexto, Prisma propone un sistema de clasificación basado en aprendizaje automático que analiza características financieras, laborales y crediticias para clasificar perfiles en tres categorías: Good, Standard y Poor.

Para desarrollar esta propuesta se construyó un conjunto de datos sintéticos de 5.000 registros con 23 variables predictoras, diseñado para representar relaciones coherentes entre las características de los usuarios y su comportamiento crediticio. Uno de los principales desafíos consiste en diferenciar categorías con características similares, debido a la naturaleza probabilística de las etiquetas generadas.

Tomando como referencia el enfoque de Koshti, Molia y Varia (2025), se compararon diez algoritmos mediante un flujo de preprocesamiento reproducible, validación cruzada y evaluación independiente. Se seleccionó una regresión logística regularizada (C = 0,001), que alcanzó un F1 macro de 0,4526 y una exactitud de 0,4520 sobre 1.000 perfiles de prueba.

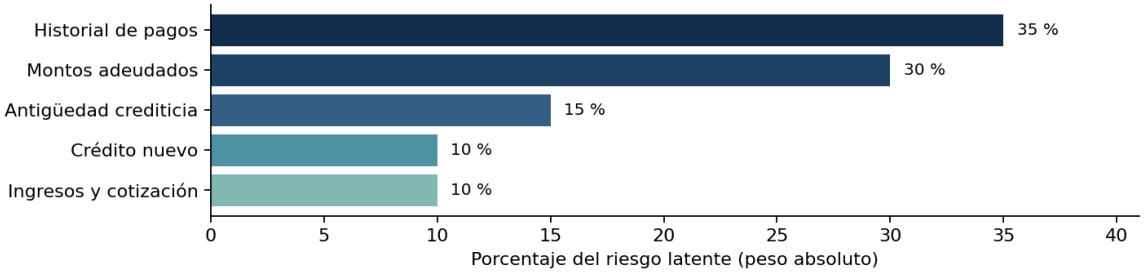
Finalmente, el modelo se integró en una aplicación interactiva desarrollada con Streamlit, que permite realizar predicciones, visualizar probabilidades e interpretar los factores que influyen en cada clasificación. Prisma demuestra así la aplicación de técnicas de aprendizaje automático a un escenario crediticio simulado, sin pretender que sus resultados sustituyan evaluaciones financieras basadas en datos reales.

2. Construcción y alcance de los datos

El archivo data/dataset_credit_score_colombia.csv contiene 5.000 filas y 25 columnas: 23 predictores, una variable derivada de antigüedad laboral excluida del entrenamiento y la etiqueta Credit_Score. Se registran cero faltantes y cero duplicados; 19 predictores son numéricos y cuatro categóricos.

Clase	Good	Standard	Poor
Registros	1.709 (34,18 %)	1.772 (35,44 %)	1.519 (30,38 %)

Simulación fundamentada. La generación encadena empleo e ingresos, cotización, productos crediticios y conducta de pago. La etiqueta procede de un índice latente con señales ponderadas inspiradas en categorías generales FICO: pagos 35 %, deuda 30 %, antigüedad 15 %, crédito nuevo 10 % y adaptación laboral 10 %. Se añade ruido normal (σ = 0,12) y muestreo softmax de tres clases. Estos pesos son supuestos del equipo, no estimaciones oficiales para Colombia.



Alcance: las etiquetas son sintéticas y no representan mora observada. Prisma no sirve para aprobar o negar créditos reales.

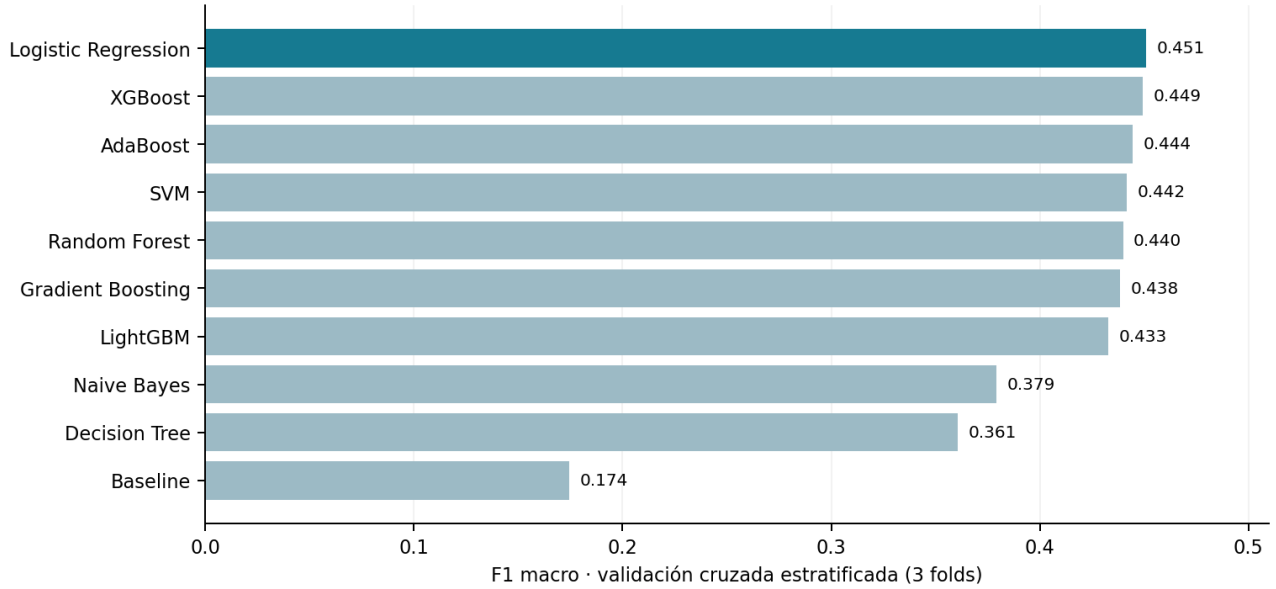
MODELAMIENTO

Pipeline, comparación y selección

Diseño experimental. Se reserva un 20 % estratificado para prueba (1.000 perfiles) y se utiliza el 80 % restante (4.000) para entrenar y seleccionar modelos, con semilla 42. El Pipeline de scikit-learn integra StandardScaler para variables numéricas y OneHotEncoder para categóricas; los ajustes ocurren dentro de cada partición de entrenamiento para prevenir fuga de datos. La métrica principal es F1 macro, que da igual peso a las tres clases.

3. Comparación de diez clasificadores

La comparación inicial usa validación cruzada estratificada de tres folds, incluyendo una línea base Dummy. La regresión logística obtuvo F1 macro CV = 0,4510; XGBoost, 0,4495; AdaBoost, 0,4444; SVM, 0,4416; Random Forest, 0,4399; y la línea base, 0,1745. Las diferencias pequeñas no prueban superioridad estadística.



4. Ajuste y validación anidada

Se ajustaron seis familias mediante GridSearchCV de tres folds. Las mejores puntuaciones de búsqueda fueron regresión logística 0,4609, Random Forest 0,4540 y SVM 0,4533. Para seleccionar entre dos finalistas se empleó validación cruzada anidada de tres folds externos y dos internos.

Finalista	F1 macro anidado	Desviación
Regresión logística	0,4619	0,0057
Random Forest	0,4544	0,0024

La regresión logística fue seleccionada por su resultado anidado, menor complejidad y capacidad de descomponer sus puntuaciones de clase. La configuración guardada es C = 0,001, solver = lbfgs, max_iter = 3000. El ajuste de hiperparámetros y la validación anidada se documentan por separado para evitar confundir puntuaciones de búsqueda con estimaciones independientes.

EVALUACIÓN INDEPENDIENTE

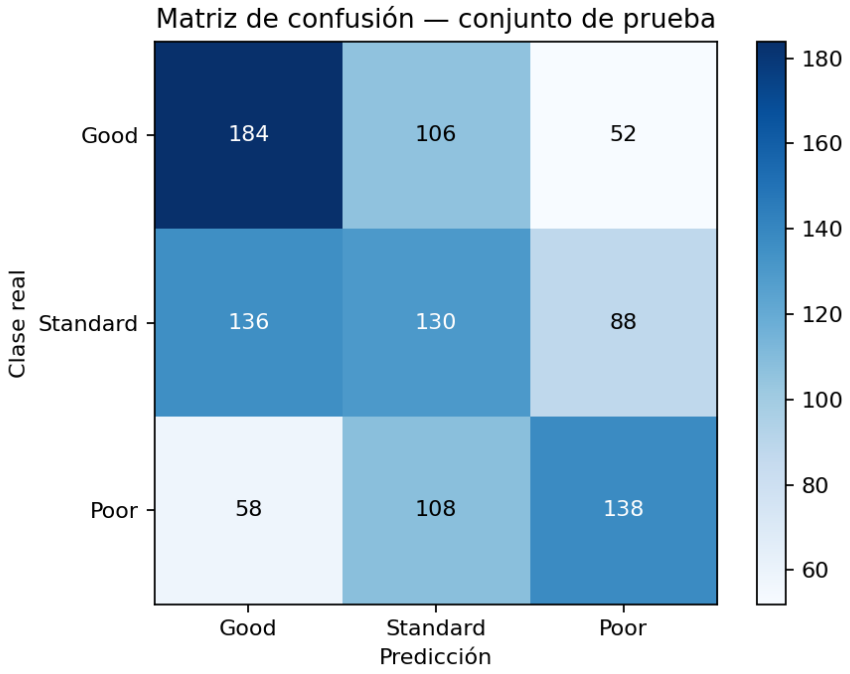
Resultados, errores e incertidumbre

El modelo seleccionado se evaluó en los 1.000 registros reservados, sin utilizarlos para elegir hiperparámetros. El desempeño es moderado: accuracy = 0,4520, precisión macro = 0,4537, recall macro = 0,4531 y F1 macro = 0,4526.

Clase	Precisión	Recall	F1	Soporte
Good	0,4868	0,5380	0,5111	342
Standard	0,3779	0,3672	0,3725	354
Poor	0,4964	0,4539	0,4742	304

5. Matriz de confusión

La clase Standard registra el menor recall (36,72 %). Entre los errores relevantes hay 58 perfiles etiquetados Poor predichos como Good y 52 Good predichos como Poor. Estos desacuerdos se refieren exclusivamente a etiquetas simuladas; no se puede inferir un costo crediticio real.



6. Variabilidad y referencia del simulador

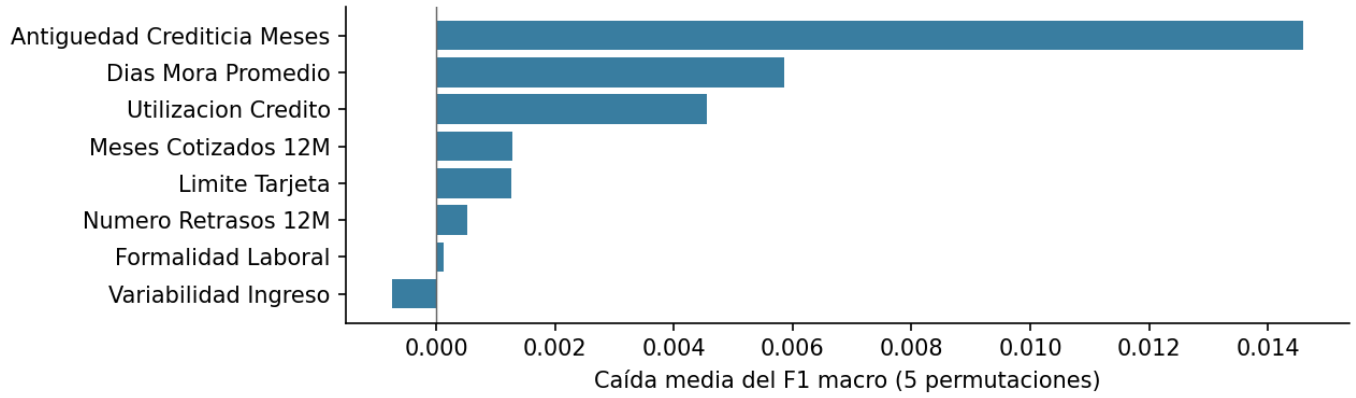
Con 1.000 remuestreos bootstrap, el intervalo de confianza del 95 % para F1 macro es [0,4219; 0,4857]. Un oráculo que conoce las probabilidades del generador sintético obtiene F1 macro = 0,5790 y accuracy = 0,5720. La brecha refleja la dificultad de recuperar etiquetas muestreadas estocásticamente; no constituye una cota de rendimiento para otros datos.

Análisis adicional. Una prueba de sensibilidad con SVM y transformación log1p de variables monetarias obtuvo F1 macro CV = 0,4586 ± 0,0042, sin cambiar la selección final. La evidencia no permite afirmar capacidad predictiva sobre incumplimientos observados.

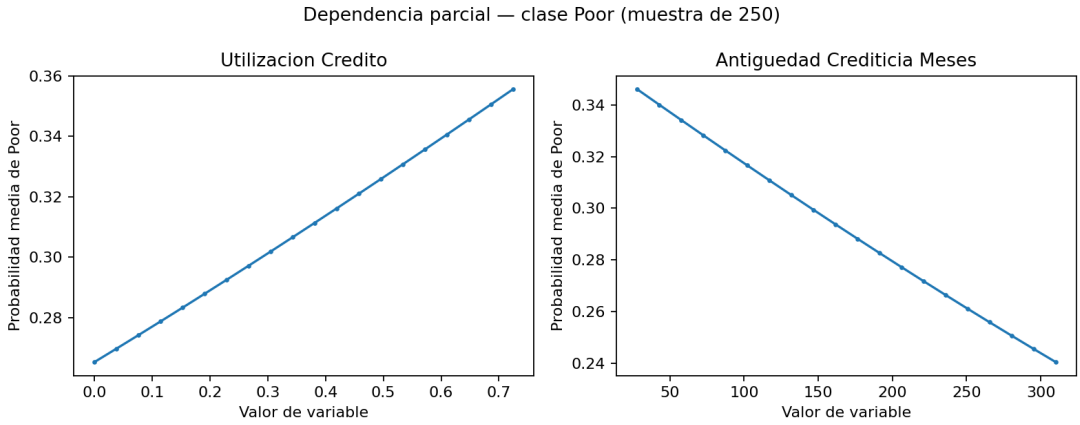
INTERPRETABILIDAD Y PRODUCTO

Explicaciones y aplicación Streamlit

Interpretabilidad global. La importancia por permutación cuantifica la disminución de F1 macro al desordenar una variable. En el archivo de cinco repeticiones destacan antigüedad crediticia (0,0146), días de mora promedio (0,0059) y utilización del crédito (0,0046). Los valores son modestos y no implican causalidad.



Dependencia parcial. En la muestra documentada de 250 perfiles, la probabilidad media predicha de Poor aumenta de 0,265 a 0,356 al variar utilización del crédito y disminuye de 0,346 a 0,240 al variar antigüedad crediticia. Son respuestas del modelo ante escenarios modificados, no efectos causales.



7. Despliegue básico: Prisma

La aplicación se desarrolla en Streamlit y Plotly y conserva el Pipeline serializado. Sus ocho páginas son Inicio, Simulador, Resultado, Comparar perfiles, Predicción por lotes, Interpretabilidad, Comparación de modelos y Metodología. El simulador valida 23 variables y aplica reglas de coherencia; Resultado presenta clase, probabilidades y explicación individual. También ofrece comparación entre perfiles y exportaciones CSV/HTML.

Explicación individual. La regresión logística permite descomponer exactamente la diferencia entre el logit del perfil y el logit promedio de entrenamiento en contribuciones de las variables transformadas. Las probabilidades corresponden a las clases del simulador y no son probabilidades calibradas de mora real.

DISCUSIÓN Y TRAZABILIDAD

Limitaciones, calidad y conclusiones

8. Validación técnica y reproducibilidad

Pruebas automatizadas. Según el registro de ejecución, se aprobaron 27 pruebas de pytest, que ejercitan los módulos, las rutas y las ocho páginas de Streamlit. Verificación manual. El 11 de noviembre de 2026 el equipo revisó las ocho secciones de la aplicación pública en Streamlit Community Cloud, que funcionó en esas pruebas; está disponible en https://prisma-riesgo-crediticio.streamlit.app/. El notebook reorganizado no se ejecutó completamente tras los cambios.

La reproducción aislada documenta coincidencia byte a byte del CSV y modelo regenerados y diferencia máxima 0,0 en predict_proba para 5.000 registros. Sin embargo, el notebook principal solo genera dos archivos de datos y cuatro de models/; otros artefactos y cinco figuras no disponen de regeneración automatizada en el repositorio. La evidencia está en resultados/reproduccion/REPRODUCCION.md.

9. Limitaciones y proyección

La validez externa es limitada por la simulación total de perfiles y etiquetas, la selección manual de pesos y parámetros, y la ambigüedad inducida por el muestreo probabilístico. Las importancias no prueban causalidad; tampoco se documentan calibración con datos observados, validación temporal ni auditoría de equidad. La presencia de edad entre los predictores exige especial atención antes de cualquier uso sensible. Como continuidad se proponen datos autorizados y anonimizados, análisis de sensibilidad, calibración, evaluación de equidad y seguimiento MLOps.

10. Conclusiones

1. Un experimento trazable, no un sistema de calificación real. Prisma integra 5.000 perfiles sintéticos, 23 predictores y tres categorías de riesgo. La generación combina variables económicas y crediticias con un mecanismo de etiquetado estocástico. Esto permite estudiar un problema multiclase completo, pero impide extrapolar los resultados a clientes, entidades financieras o tasas reales de incumplimiento.

2. La selección del modelo debe sustentarse en validación. Entre diez clasificadores, la regresión logística regularizada fue elegida por su resultado en validación anidada (F1 macro = 0,4619), su simplicidad y su interpretabilidad. En la prueba independiente obtuvo F1 macro = 0,4526, con intervalo bootstrap del 95 % de 0,4219 a 0,4857. La clase Standard presentó el desempeño más débil, por lo que el promedio global no debe ocultar las diferencias entre clases.

3. La interpretación aporta valor, pero tiene límites. La matriz de confusión permite localizar errores concretos, mientras que la importancia por permutación y las curvas de dependencia parcial describen el comportamiento del clasificador. Ninguno de esos análisis establece relaciones causales. La incertidumbre introducida por las etiquetas simuladas y la falta de validación con datos observados obligan a presentar las probabilidades como resultados del modelo, no como riesgo financiero calibrado.

4. El despliegue completa el ciclo de Machine Learning. La aplicación Streamlit conecta el modelo serializado con validaciones de entrada, simulación individual, comparación de perfiles, predicción por lotes y visualización de resultados. Las pruebas automatizadas y las verificaciones manuales documentadas respaldan su funcionamiento. Para avanzar hacia un contexto real serían necesarios datos autorizados, evaluación de equidad, calibración, validación temporal y monitoreo.

Referencias bibliográficas

Koshti, R. M., Molia, S. J. y Varia, D. J. (2025). Improving Credit Score Classification Using Predictive Analysis and Machine Learning Techniques. IJSAT. · FICO. What’s in your credit score? · Gutiérrez-Rueda, Estrada y Capera-Romero (2011). Banco de la República.

Fuentes institucionales de contexto: DANE (GEIH), UGPP, Superintendencia Financiera de Colombia y Banca de las Oportunidades.

Declaración de uso de inteligencia artificial

Durante el desarrollo de Prisma se utilizaron herramientas de inteligencia artificial generativa como apoyo en algunas tareas de diseño visual, organización de contenidos, redacción y presentación de resultados. Su uso fue complementario al trabajo del equipo; la selección de modelos, la interpretación de métricas y las decisiones técnicas deben ser comprendidas y sustentadas por sus integrantes.